Национальный исследовательский университет ИТМО
Факультет информационных технологий и программирования
Прикладная математика и информатика

Методы оптимизации

Отчет по лабораторной работе №3

⟨Собрано 11 июня 2023 г.⟩

Работу выполнили:
Бактурин Савелий Филиппович M32331
Вереня Андрей Тарасович M32331
Сотников Максим Владимирович M32331

Преподаватель:
Ким Станислав Евгеньевич

Решение задачи нелинейной регрессии

Часто решая задачу создания регрессионной модели мы сталкиваемся с тем, что по жизни очень немногие рассматриваемые функции оказываются не представимы в виде обобщенной линейной зависимости или полиномиальной некоторой конечной степени k. Такая же ситуация часто случается и с некоторым набором данных, который нужно как-то обобщить. Именно в таких случаях к нам на помощь приходит более частный случай регрессионного анализа – *нелинейная регрессия.*

Идея построения нелинейной регрессии как и в случае с полиномиальной заключается в том, чтобы найти математическую функцию, которая максимально точно описывает зависимость между независимой переменной и зависимой от нее. Например, для построения нелинейной регрессии можно использовать функции типа полинома, логарифмической или экспоненциальной зависимости.

В целом весь процесс нахождения нелинейной регрессионной модели можно поделить на два этапа:

- ▷ Определить регрессионную модель $f(w, x)$, которая зависит от параметров $w = (w_1,\ \ldots,\ w_W)$ и свободной переменной x.
- ▷ Решить задачу по нахождению минимума сумма квадратов регрессионных остатков:

$$S = \sum_{i=1}^{m} r_i^2,\ r_i = y_i - f(w, x_i)$$

Однако, решая в лоб такую задачу, мы сталкиваемся с оптимизационной задачи нахождения параметров нелинейной регрессионной модели. Тут к нам и приходят на помощь различные методы нахождения, в том числе и рассматриваемые ниже: *Gauss-Newton* и *Powell Dog Leg.*

Gauss-Newton

Напомним, что мы решаем следующую задачу: дана нелинейная модель $f(w, x)$, где $w \in \mathbb{R}^m$, тогда сумма квадратов регрессионных остатков высчитывается как

$$S = \sum_{i=1}^{\texttt{sizeof}\ X} (f(w, x_i) - y_i)^2 \to \min$$

Итак, пусть $n = \texttt{sizeof}\ X$ и введем некоторые новые объекты для решения задачи, пусть $w^0 = (w_0^0,\ w_1^0,\ \ldots,\ w_m^0)$ – начальное приближение, и

$$\begin{aligned}
&\mathbb{J} = \left(\frac{\partial f}{\partial w_j}(w^{\mathbf{i}}, x_i)\right)_{n\times m} \ -\ \text{Якобиан, или матрица первых производных}\\
&\vec{f_{\mathbf{i}}} = \left(f(w^{\mathbf{i}}, x_i)\right)_{n\times 1} \ -\ \text{вектор значений функции } f\\
&\eth_{\mathbf{i}} = \texttt{const} \ -\ \text{размера шага}
\end{aligned}$$

Тогда, формула $\mathbf{i}$-й итерации рассматриваемого метода будет высчитываться как

$$w^{\mathbf{i}+1} \leftarrow w^{\mathbf{i}} - \eth_{\mathbf{i}} \cdot \underbrace{\left(\mathbb{J}_{\mathbf{i}}^{\mathrm{T}}\mathbb{J}_{\mathbf{i}}\right)^{-1}\mathbb{J}_{\mathbf{i}}^{\mathrm{T}}}_{\beta}(\vec{f_{\mathbf{i}}} - y),$$

где β – это псевдообратная матрица к матрице $\mathbf{J_i}$, или решение некоторой задачи многомерной линейной регрессии, где мы ищем такой вектор β, что

$$\left\| \mathbf{J_i}\beta - (\vec{f_\mathbf{i}} - y) \right\|^2 \to \min,$$

где y – вектор правильных/настоящих ответов нашей модели. Получается, для решения задачи, мы, так называемую, *невязку* пытаемся приблизить линейной комбинацией вектора из матрицы Якобиана так, что при следующем шаге итерации получить такой $w^{\mathbf{i}+1}$, который бы сократил нам расстояние невязки. Причем, заметим, что на каждом шаге, задача будет новой, так как $\mathbf{J_i}$ зависит от текущего приближения, чтобы решить задачу многомерной регрессии.

Заметим, что здесь, по алгоритму, мы видим достаточно очевидное ограничение: $m \geqslant n$, в ином случае для $\mathbf{J_i}^{\mathrm{T}}\mathbf{J_i}$ не будет существовать обратной матрицы и, в следствии, решения к уравнению.

Исследования

Powell Dog Leg

Trust-region method — это метод решения оптимизационных задач, который основывается на вычислении региона, в котором квадратичная модель аппроксимирует целевую функцию. Сам этот метод представляет из себя смесь сразу двух алгоритмов, решающих задачу:

- ▷ Линейный поиск используется для определения направления поиска и дальнейшего нахождения оптимального шага вдоль выбранного вектора пути.
- ▷ Сам по себе trust-region используется для определения области вокруг текущей итерации, в котором модель достаточно аппроксимирует целевую функцию. Причем, стоит заметить, что для поиска следующего радиуса рассматриваемого региона также будет использоваться линейный поиск.

В общем случае Trust-region на каждой итерации решает следующую квадратичную задачу:

$$\min_{p \in \mathbb{R}^n} m_k(p) = f_k + p^{\mathrm{T}} g_k + \frac{1}{2} p^{\mathrm{T}} B_k p,$$

где $f_k = f(x_k)$, $g_k = \nabla f_k$, $B_k = \nabla^2 f_k$ и $\nabla_k > 0$ – изменяющийся радиус региона, причем всё это, при условии, что $|p| \leqslant \nabla_k$. Заметим, что в таком простейшем виде мы получаем безусловно почти бесполезный алгоритм: он чрезвычайно медленный из-за появления B_k – Гессиана функции. С другой стороны, если он положительно определен и $|B_k^{-1} \nabla f_k| \leqslant \nabla_k$, то решение легко определить: $p_k^B = -B_k^{-1} \nabla_k$. Но, опять же, высчитывать еще и обратную матрицу – дело долгое и медленное, поэтому, начиная отсюда и до конца все лабораторной работы, мы будем то и дело пытаться приближать наши значения к реальным/по настоящему посчитанным значениям Гессиан-функции.

Здесь мы рассмотрим один из методов оптимизации при аппроксимации квадратичной модели – *Powell Dog Leg*. Начнем, пожалуй, с определения радиуса рассматриваемого доверительного региона: в алгоритме dogleg обычно выбирают основываясь на сходстве функции m_k (та, что мы решаем изначально) и оригинальной

функции f на предыдущей итерации. Зададим ρ_k следующим образом:

$$\rho_k = \frac{f_k - f_k^\star}{m_k(0) - m_k(p_k)},$$

где $f_k^\star = f(x_k + p_k)$. А теперь посмотрим на то, как именно лучше поменять шаг: в том случае, если ρ_k меньше нуля, то это значит, что наша модель далека от функции и нужно обязательно уменьшить радиус; в том случае, изменение функции почти не изменилось и мы попали на границу региона, то есть смысл увеличить радиус; в ином другом случае – остается неизменным.

$$\Delta_{k+1} = \begin{cases} \frac{1}{4}\Delta_k, & \rho_k < \frac{1}{4} \\ \min\left(2\Delta_k,\ \Delta_{\texttt{max}}\right), & \rho_k > \frac{3}{4} \wedge \|p_k\| = \Delta_k \\ \Delta_k, & \text{в ином другом случае} \end{cases}$$

Наконец, начинается самое интересное со стороны Powell Dog Leg. Итак, мы находимся на некоторой точки нашей модели, есть подсчитанный Δ-радиуса доверительного региона, и посмотрим на полный шаг $p^B = -B^{-1}g$. Если p^B лежит в окружности региона, то мы можем его взять и более закончить алгоритм. В ином случае, рассмотрим анти-градиент $-g$ и попробуем вдоль нее поискать минимум квадратичной модели, то есть решить

$$\min_{\|-\tau g\| \leqslant \Delta} m(-\tau g)$$

Для её решения мы можем взять некую новую точку без каких-либо ограничений в направлении анти-градиента и найти минимум модели

$$p^U = -\frac{g^{\mathrm{T}} g}{g^{\mathrm{T}} B g} g$$

Здесь снова две ситуации, где может находиться т. p^U:

- ▷ Если она находится вне рассматриваемой области, то мы можем взять точку на границе и шагнуть туда.
- ▷ Если же она находится в окружности, то построим отрезок $p^U p^B$ и начнем искать минимум вдоль этих двух линий $\left(\text{текущая} \to p^U \text{ и } p^U \to p^B\right)$.

Наконец, вдоль пути мы рассматриваем траекторию $\hat{p}(\tau)$

$$\hat{p}(\tau) = \begin{cases} \tau p^U, & 0 \leqslant \tau \leqslant 1 \\ p^U + (\tau - 1)(p^B - p^U), & 1 \leqslant \tau \leqslant 2 \end{cases}$$

Подытожим. Мы получили, на самом деле, в чем-то схожий на метод Гаусса-Ньютона алгоритм нахождения схождения, в частности, кстати, точка p^B – это то, куда бы шагнул метод Гаусса-Ньютона, но при этом, если эта точка удовлетворяет нашим потребностям, то мы действуем как Гаусс-Ньютон, в ином случае – чуть по другому. Причем под «немного другим» способом предполагается, на самом деле, хитрая комбинация Гаусса-Ньютона и градиентного спуска (так как при маленьком доверительном регионе мы пойдем по направлению, близкому градиентному спуску).

Исследования

BFGS

BFGS, или Алгоритм Бройдена - Флетчера - Гольдфарба - Шанно – это тоже оптимизационный итерационный алгоритм для нахождения локального экстремума для не представимых данных или функций в линейном/полиномиальном виде.

Один из известных квазиньютоновских методов (то есть, тех, которые основаны на получении информации о кривизне функции). Как и в случае с Powell Dog Leg, данный метод, в отличии от многих квазиньютоновских, использует аналог довольно медлительного постоянного переопределения Гессиана функции. Но если предыдущий механизм никак не взаимодействовал с явным Гессианом, то BFGS, наоборот, ускоряет работу на порядок: ибо он не явно каждый раз высчитывает матрицу, а лишь приближает к ней значения, при этом посчитав по честному Гессиан лишь один раз.

Рассмотрим идею этого алгоритма. Обозначим за $x_i = \{x_i^0,\ x_i^1,\ \ldots,\ x_i^{n-1}\}$ – координата в пространстве, где n – размерность соответствующего пространства. Пусть дана нам некоторая функция $f(x)$ и, как обычно, решаем задачу оптимизации нахождения $\underset{x}{\operatorname{argmin}} f(x)$. Тогда, зададим некую начальную точку x_0 и $H_0 = B_0^{-1}$ – начальное приближение, где B_0^{-1} – обратный Гессиан функции, который или может быть посчитан в точке x_0, или выбран как $\mathbf{I}$ – обратная матрица. Наконец, сам алгоритм:

0) Пусть k – текущий номер итерации алгоритма.

1) Находим точку, в направлении которой будем производить поиск, она определяется следующим образом

$$p_k = -H_k \times \nabla f_k,$$

где здесь и далее $f_k = f(x_k)$.

2) Вычисляем x_{k+1} через рекуррентное соотношение следующего вида:

$$x_{k+1} = x_k + \alpha \cdot p_k,$$

где α – коэффициент, удовлетворяющий условиям Вольфа, которые, напомню, выглядят вот так

$$\begin{aligned} f(x_k + \alpha \cdot p_k) &\leqslant f(x_k) + c_1 \cdot \alpha \cdot \nabla f_k^T p_k \\ \nabla f(x_k + \alpha \cdot p_k)^T p_k &\geqslant c_2 \cdot \nabla f_k^T p_k \end{aligned}$$

3) Теперь определим размер шага алгоритма после данной итерации и изменение градиента следующими соответствующими образами

$$\begin{aligned} s_k &= x_{k+1} - x_k \\ y_k &= \nabla f_{k+1} - \nabla f_k \end{aligned}$$

4) Наконец, обновим Гессиан функции, зная, что $\lambda = \dfrac{1}{y_k^{\mathrm{T}} s_k} \in \mathbb{R}$

$$H_{k+1} = \left(\mathbf{I} - \lambda s_k y_k^{\mathrm{T}}\right) H_k \left(\mathbf{I} - \lambda y_i s_k^{\mathrm{T}}\right) + \lambda s_k s_k^{\mathrm{T}}$$

Пример

Возьмем в качестве примера функцию $f(x, y) = \sin(0.5x^2 - 0.25y^2 + 3) \cdot \cos(2x + 1 - e^y)$. В качестве начальной точки возьмем $\langle x_0, y_0 \rangle = \langle -0.3, -1.3 \rangle$ и запустим зверя.

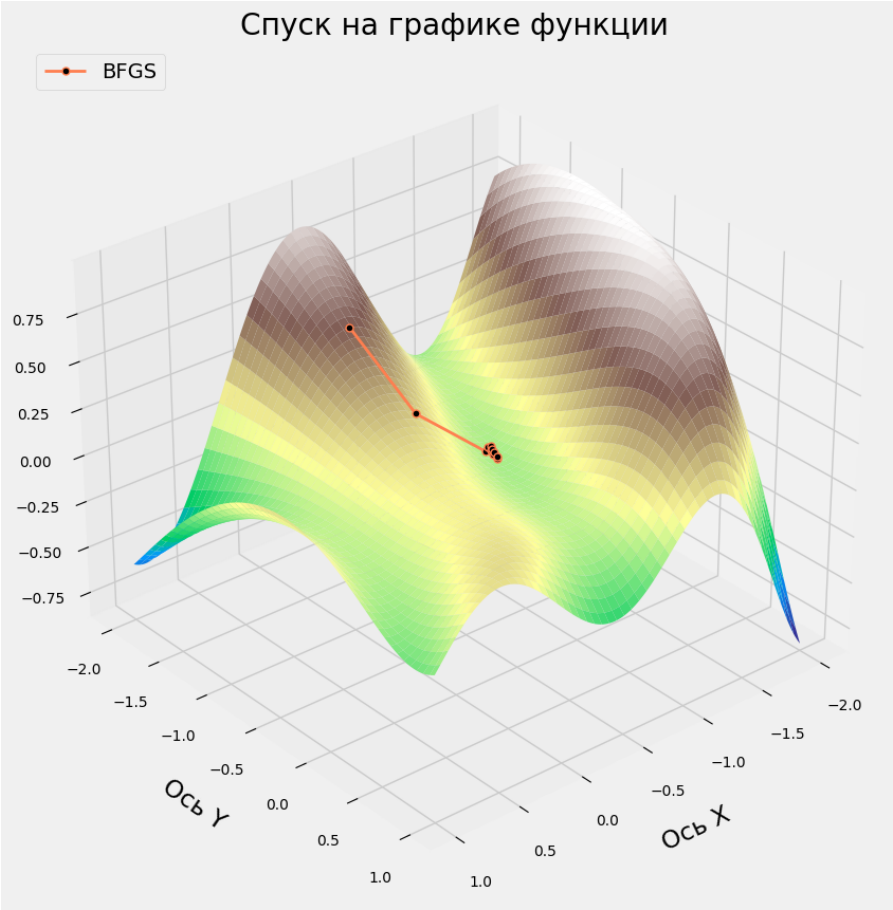

Example of BFGS

Полученные результаты столь небольшого примера с неприятным минимум следующие. Алгоритм сошелся к предполагаемой точке минимум за 11 шагов, после этого умер своей смертью (условие схождения). Полученная точка $z_{\texttt{min}} = -0.040723$, а его прообразом служит пара из $\langle -0.848456, -0.605206 \rangle$. Тот же путь алгоритма в виде линий уровня:

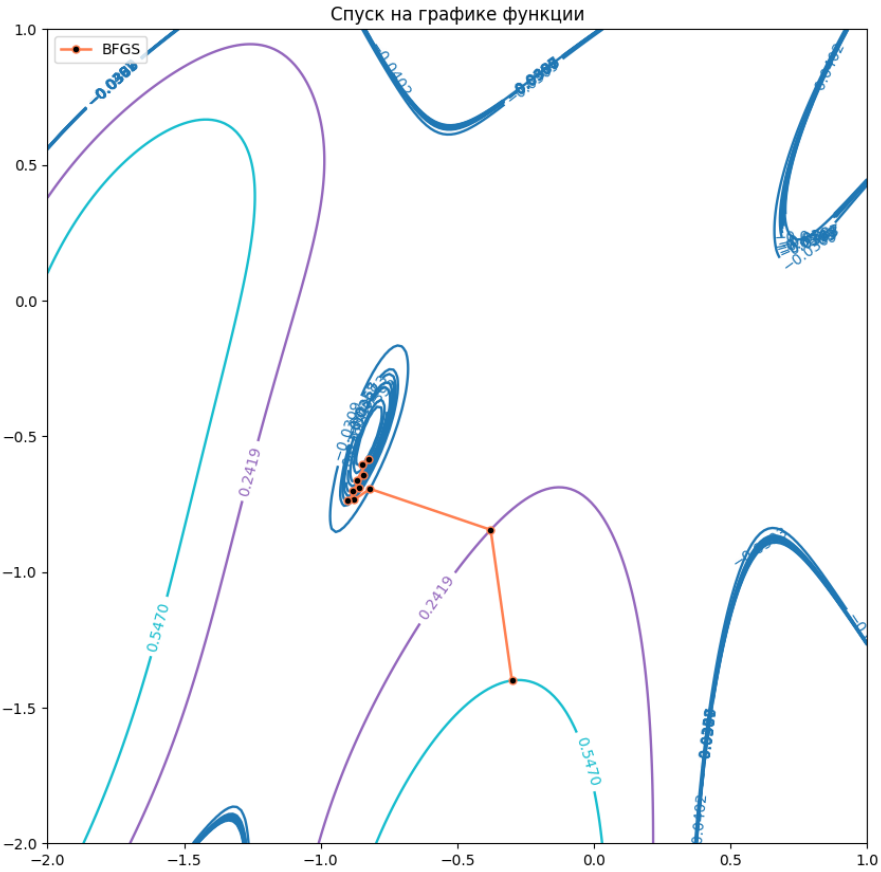

Example of BFGS (lines)

Исследования

Заметим, что исследования чистой полилинейной регрессии с методом нахождения минимальной или максимальной точки функции выглядит задачей странной, так как там нам нужен сгенерированный dataset, а здесь начальное приближение. Поэтому, в качестве рейтинга H(onest) за честность, мы воспользуемся BFGS как методом минимизации ошибки квадратичного уравнения. Его соперником выступит ранее известный нам Adam, а все-все исследования будем проводить на, внезапно, очень простой полилинейной функции $f(x) = 2 \cdot x$. Зададим следующие настройки генерации точек:

$$\texttt{dots\_count} = 500 \text{ (количество точек)}$$
$$\texttt{variance} = 0.5 \text{ (вариативность, константа, используемая в формуле генерации)}$$
$$\texttt{max\_epoch} = 16 \text{ (максимальное количество точек)}$$
$$\texttt{batch\_min\_size} = 0 \text{ (минимальный размер батча)}$$
$$\texttt{batch\_max\_size} = 500 \text{ (максимальный размер батча)}$$

Будем проводить исследования, подобно предыдущей лабораторной работы, на размере батча $\texttt{batch\_size} \in [\texttt{batch\_min\_size}, \texttt{batch\_max\_size}]$. В качестве Adam мы возьмем результаты предыдущей лабораторной работы. Итак, полученный график.

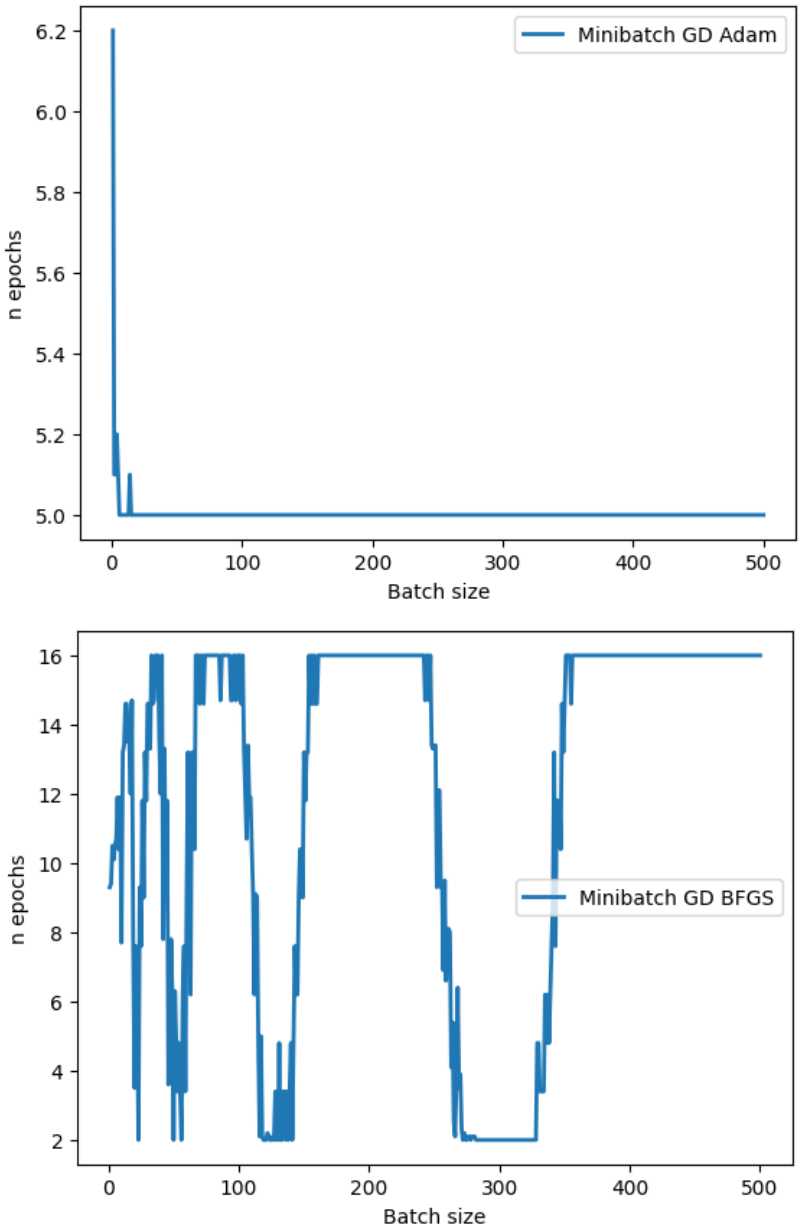

(Minibatch GD) Adam vs. BFGS

Заметим, что в большинстве случаев BFGS, по с течению обстоятельств, проигрывает великолепному Adam, у которого, по предыдущей работе, количество шагов почти никогда не изменялось и оставалось в среднем 5. Также, на некоторых промежутках размеров батча BFGS всё же выигрывает гонку у Adam. Почему это может происходить? На самом деле, проблема кроется в задаче, которую мы поставили перед методами, если Adam идеален в задачах линейной регрессии, то BFGS все-таки хорош во многих нелинейных функциях (смотри пример выше). На примере выше мы видели, что BFGS среди множества похожих окрестностей точек минимума находит тот самый настоящий и остаётся там.

Теперь давайте немного «приблизимся» к батчу $[0, 10]$ и $[0, 30]$ и посмотрим, что там происходит. Полученный график.

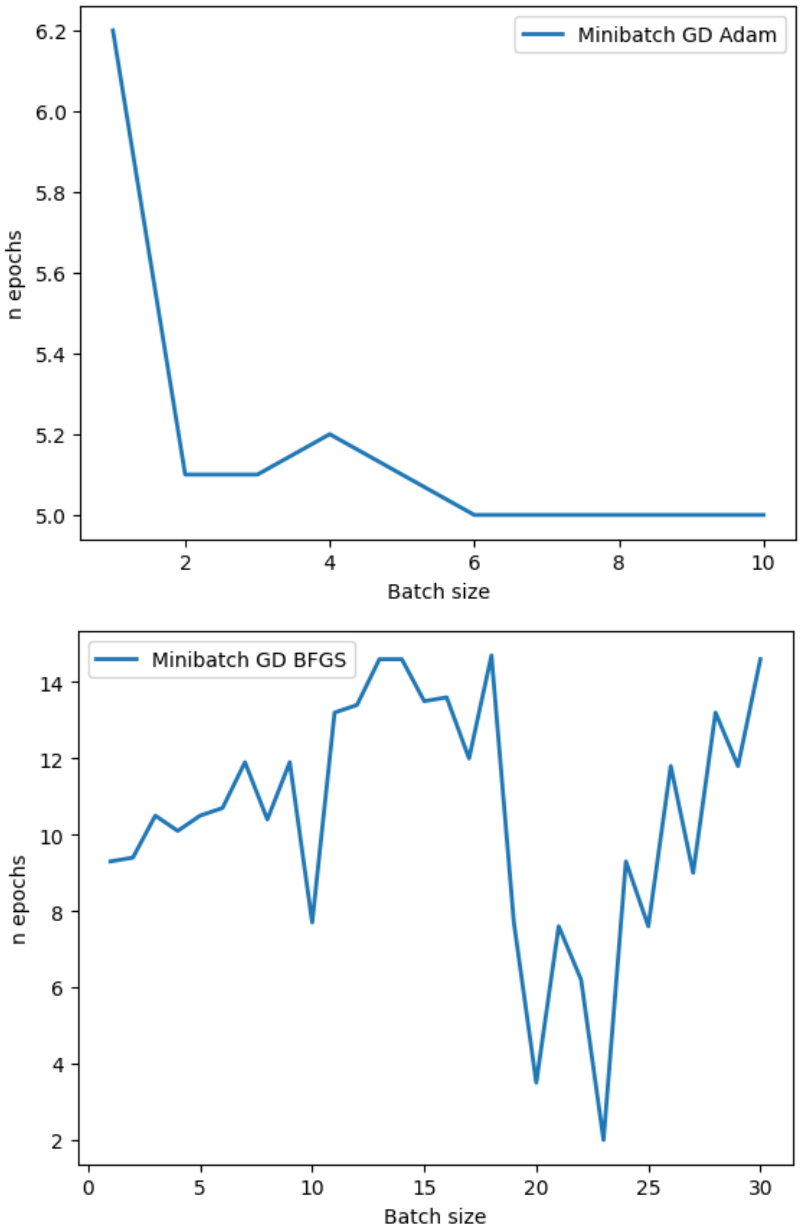

((Minibatch GD) Adam vs. BFGS) $\in [0, 10]$ и $\in [0, 30]$

Adam стремительно набирает скорость и падает вниз, в то время как BFGS, невооруженным взглядом заметное, что у него также скачкообразные шаги. При этом мы вновь видим, что при некоторых батчах также выигрывает Adam при двух или трех шагах, в отличие от пяти.

Наконец, рассмотрим повнимательнее отрезок $[200, 500]$ у обоих методов и проанализируем. Получим графики.

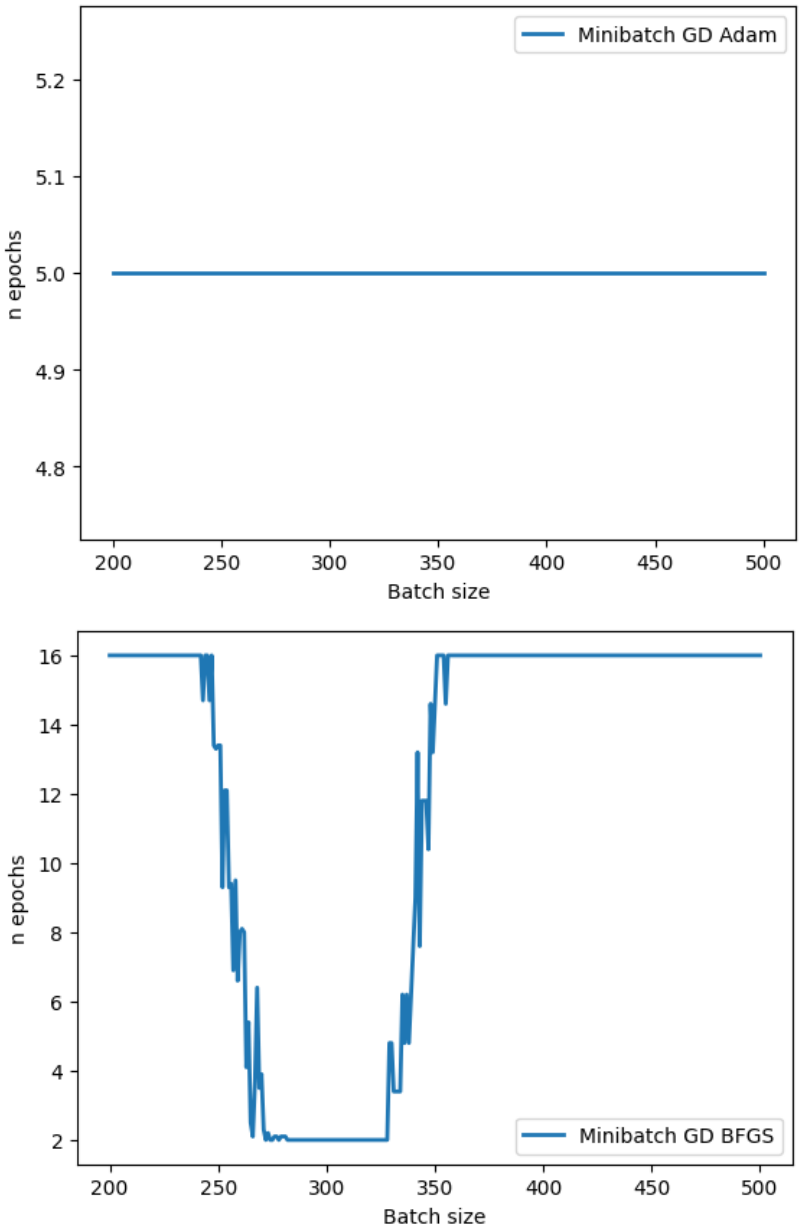

((Minibatch GD) Adam vs. BFGS) $\in [200, 500]$

Adam не желает перемен, в то время как BFGS пытается прогрессировать и скачкообразными шагами на промежутке от $[250 + \varepsilon, 325 + \delta]$ и доходит до минимального количества шагов.

Подытожим результаты. Как мы видим, BFGS плохо справляется с минимизацией относительно столь простых функцией как прямая $f(x) = 2x$. Однако, в тоже время, достаточно неплохо справляется нелинейными функциями, то есть теми, которые нельзя представить как конечный полином.

L-BFGS

L-BFGS, или BFGS с ограниченной памятью – это оптимизационный алгоритм, который аппроксимирует оригинальный алгоритм BFGS с использованием заданного ограниченного объема памяти.

L-BFGS как и BFGS использует приближенную оценку Гессиана, при этом в явном виде посчитав только один раз, а все остальные шаги лишь преобразовывая. Проблема: BFGS хранит всегда $n \times n$ приближений к обратному Гессиану. Решение: хранить несколько векторов, которые неявно представляют приближение, представляющие из себя историю последних m обновлений положения x и градиента $\nabla f(x)$. При этом, m обычно выбирается небольшим ($m < 10$).

Рассмотрим идею этого алгоритма. Во многом она будет совпадать с предыдущим, поэтому пропустим обозначения и перейдем сразу алгоритму.

0) Пусть k – текущий номер итерации алгоритма, здесь и далее будем иметь ввиду $g_k = \nabla f(x_k)$.

1) Также как и в BFGS находим точку, в направлении которой будем производить поиск:
$$p_k = -H_k \times \nabla f_k,$$
здесь и далее $f_k = f(x_k)$.

2) Пусть мы сохранили m обновлений вида:
$$s_k = x_{k+1} - x_k$$
$$y_k = g_{k+1} - g_k$$
Заметим, что при последующих итерациях алгоритма $k \geqslant m$ произведение из первого шага можно получить выполнив последовательность скалярных произведений и суммирования векторов, включающую ∇f_k и пары $\{s_i, y_i\}$. После вычисления новой итерации самая старая пара векторов в наборе пар $\{s_i, y_i\}$ заменяется новой парой, который получается из данного шага.

3) Наконец, пожалуй, самая идейная часть – обновление Гессиана. На итерации k у нас определен x_k и пары $\{s_i, y_i\}$ $\forall i \in [k-m,\ k-m+1,\ \ldots,\ k-1]$. Выберем некоторое начальное Гессианское приближение H_k^0 (в отличие от стандартной итерации BFGS, это начальное приближение может меняться от итерации к итерации) и путем повторного применения формулы, заданной изначально в BFGS, получаем
$$\begin{aligned} H_k = {} & (V_{k-1}^{\mathrm{T}} \cdot \ldots \cdot V_{k-1}^{\mathrm{T}}) H_k^0 (V_{k-m} \cdot \ldots \cdot V_{k-1}) \\ & + \rho_{k-m}(V_{k-1}^{\mathrm{T}} \cdot \ldots \cdot V_{k-m+1}^{\mathrm{T}}) s_{k-m} s_{k-m}^{\mathrm{T}} (V_{k-m+1} \cdot \ldots \cdot V_{k-1}) \\ & + \rho_{k-m+1}(V_{k-1}^{\mathrm{T}} \cdot \ldots \cdot V_{k-m+2}^{\mathrm{T}}) s_{k-m+1} s_{k-m+1}^{\mathrm{T}} (V_{k-m+2} \cdot \ldots \cdot V_{k-1}) \\ & + \ldots \\ & + \rho_{k-1} s_{k-1} s_{k-1}^{\mathrm{T}}, \end{aligned}$$
где $\rho_k = \dfrac{1}{y_k^{\mathrm{T}} s_k}$, $V_k = \mathbf{I} - \rho_k y_k s_k^{\mathrm{T}}$. Из всего вышеописанного мы можем провести произведение $H_k \times \nabla f_k$ более эффективно следующим образом

$\alpha \leftarrow$ `[0] * sizeof` s;
$q \leftarrow \nabla f_k$;
$\forall i = k-1,\ k-2,\ \ldots,\ k-m$ `do`
$\alpha_i \leftarrow \rho_i s_i^{\mathrm{T}} q$;
$q \leftarrow q - \alpha_i y_i$;
`end`
$r \leftarrow H_k^0 q$;
$\forall i = k-m,\ k-m+1,\ \ldots,\ k-1$ `do`
$\beta \leftarrow \rho_i y_i^{\mathrm{T}} r$;
$r \leftarrow r + s_i(\alpha_i - \beta)$;
`end`
`return` $(-1) \cdot r \, [\![\equiv H_k \times \nabla f_k]\!]$;

Получение нового на данной итерации H_k^0 мы также сильно ускорим, лишь приблизив наши значения, используя формулу $H_k^0 = \gamma_k \mathbf{I}$, где

$$\gamma_k = \frac{s_{k-1}^{\mathrm{T}} y_{k-1}}{y_{k-1}^{\mathrm{T}} y_{k-1}}$$

4) Все последующие шаги аналогичны с оригинальным BFGS.

Итак, напишем идейный псевдокод алгоритма L-BFGS.

```
function is_convergence(f : ℝ^n → ℝ):
    /*implementation defined*/

function Wolfe_coefficient(f : ℝ^n → ℝ, p_k):
    /*implementation defined*/

function get_prod(f : ℝ^n → ℝ):
    α ← [0] * sizeof s;
    q ← ∇f_k;
    ∀i = k−1, k−2, ..., k−m do
        α_i ← ρ_i s_i^T q;
        q ← q − α_i y_i;
    end
    r ← H_k^0 q;
    ∀i = k−m, k−m+1, ..., k−1 do
        β ← ρ_i y_i^T r;
        r ← r + s_i(α_i − β);
    end
    return (−1) · r [[≡ H_k × ∇f_k]];

function LBFGS():
    x_0 ← INIT;
    m ← i ∈ [5, 10];
    q ← []
    while !is_convergence(f) do
        H_k^0 ← ((s_{k−1}^T y_{k−1}) / (y_{k−1}^T y_{k−1})) I;
        p_k ← get_prod(f);
        α_k ← Wolfe_coefficient(f, p_k);
        x_{k+1} ← x_k + α_k p_k
```

```
30          if k > m then
31              q.remove({s_{k-m}, y_{k-m}});
32          s_k ← x_{k+1} − x_k;
33          y_k ← ∇f_{k+1} − ∇f_k;
34          q.append({x_k, y_k});
35
```

Пример

Возьмем в качестве примера функцию Растригина, описываемая как $f(\vec{x}) = 10n + \sum_{i=1}^{n} \left(x_i^2 - 10 \cdot \cos(2 \cdot \pi \cdot x_i)\right)$, где $-5.12 \leqslant x_i \leqslant 5.12$, n – исследуемая размерность. Здесь глобальный минимум $f(0, \ldots, 0) = 0$. В качестве начальной точки возьмем далеко от минимума и запустим зверя.

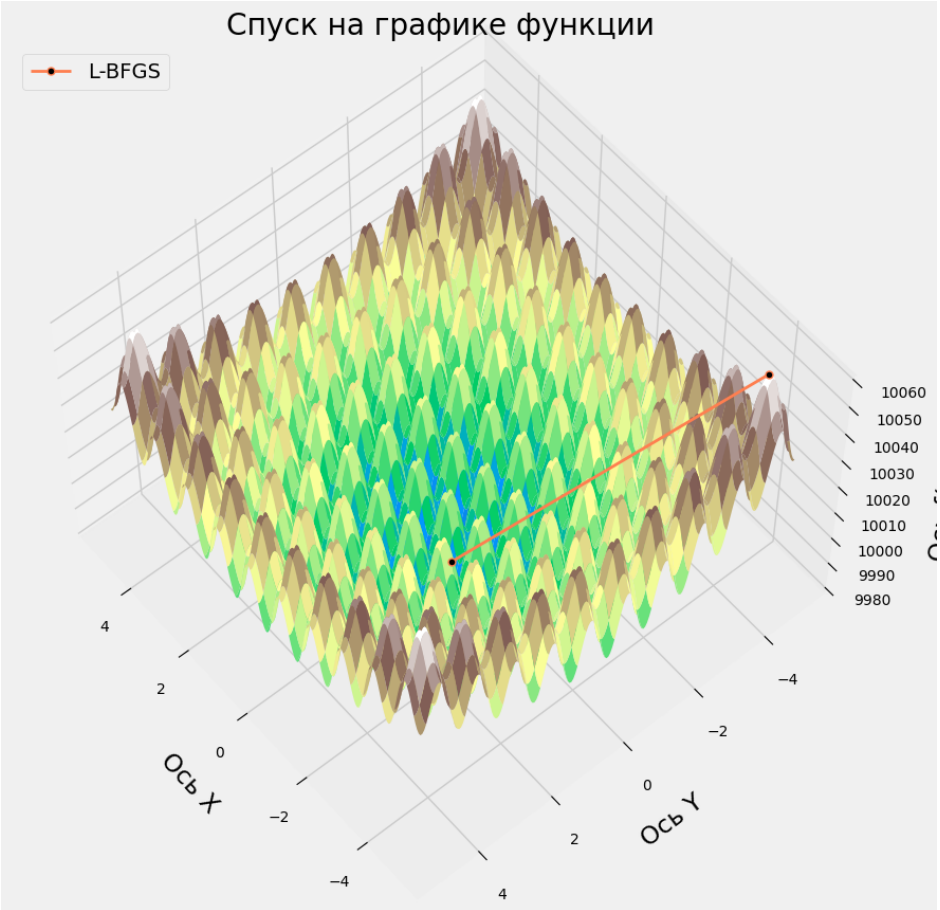

Example of L-BFGS

— "Туда нам надо – сказал L-BFGS и сделал один длинный шаг ровно в минимум. Полученная точка примерно такая же, что и заявленный минимум.

Исследования

В качестве исследования здесь мы проведем аналогичные как и в BFGS. То есть, та же функция $f(x) = 2x$, и Adam как метод минимизации для линейной регрессии. Итак, зададим те же настройки и получим полный график по батчам $[0, 500]$.

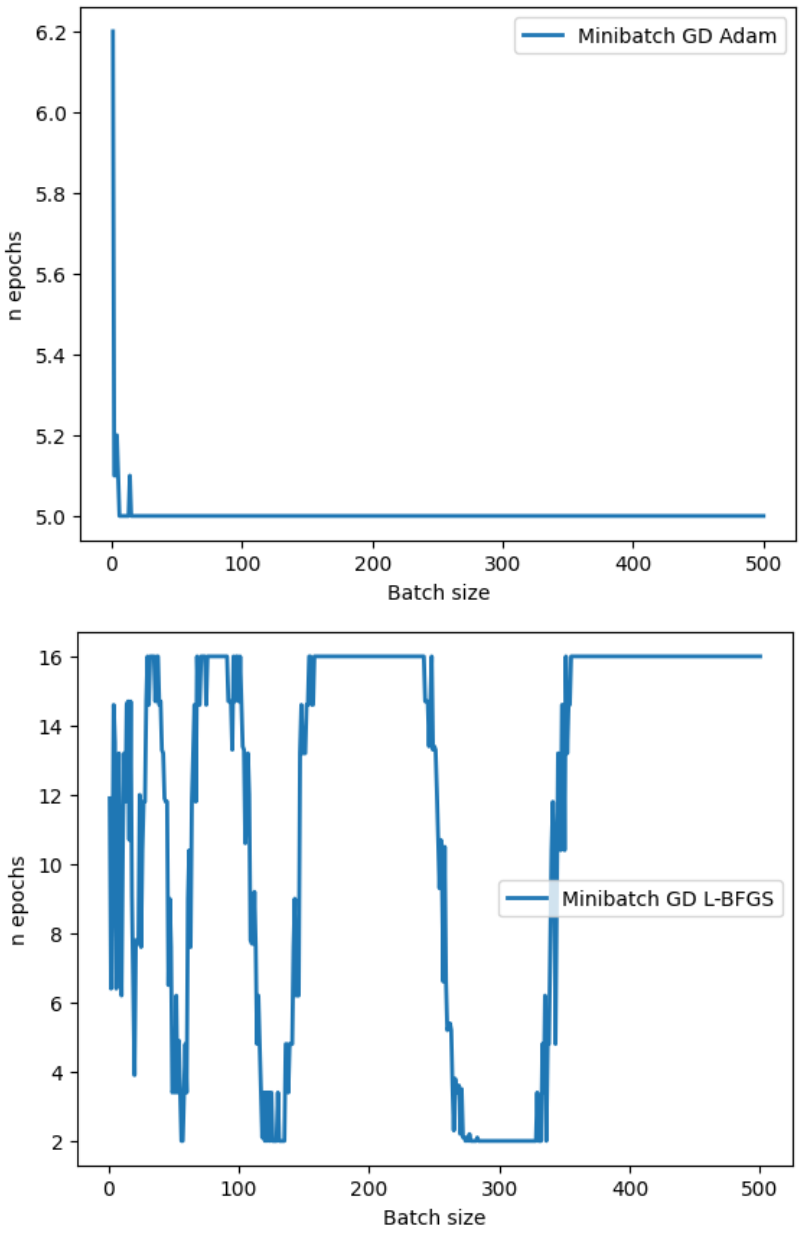

(Minibatch GD) Adam vs. L-BFGS

Получаем аналогичные результаты, что и предыдущий пациент. Связано это с тем, что там и здесь используется одна и та же идея, и, по сути, разница лишь в использовании памяти, которую BFGS жрет как не в себя. Аналогично рассмотрим наши результаты поближе на отрезке $[200, 500]$:

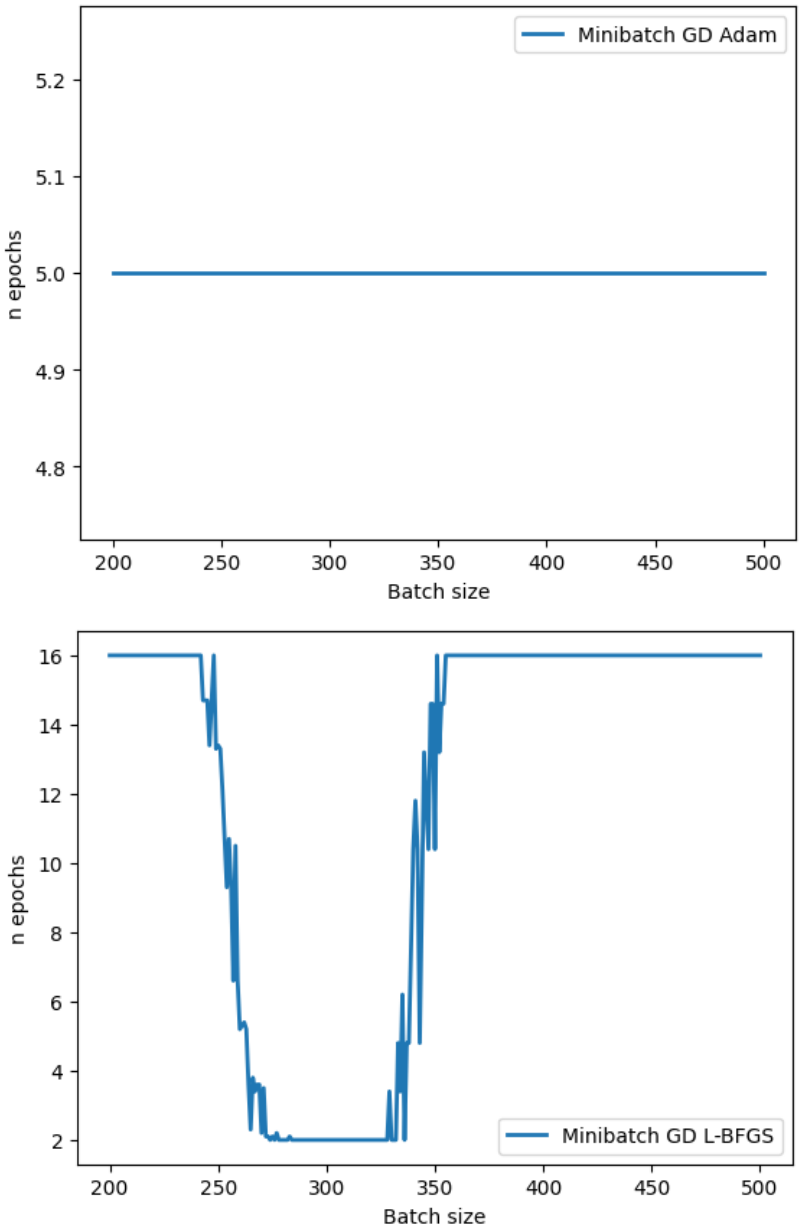

((Minibatch GD) Adam vs. L-BFGS) $\in [200, 500]$

И, наконец, приближении в отрезок $[0, 10]$ и $[0, 30]$ в случае с LBFGS:

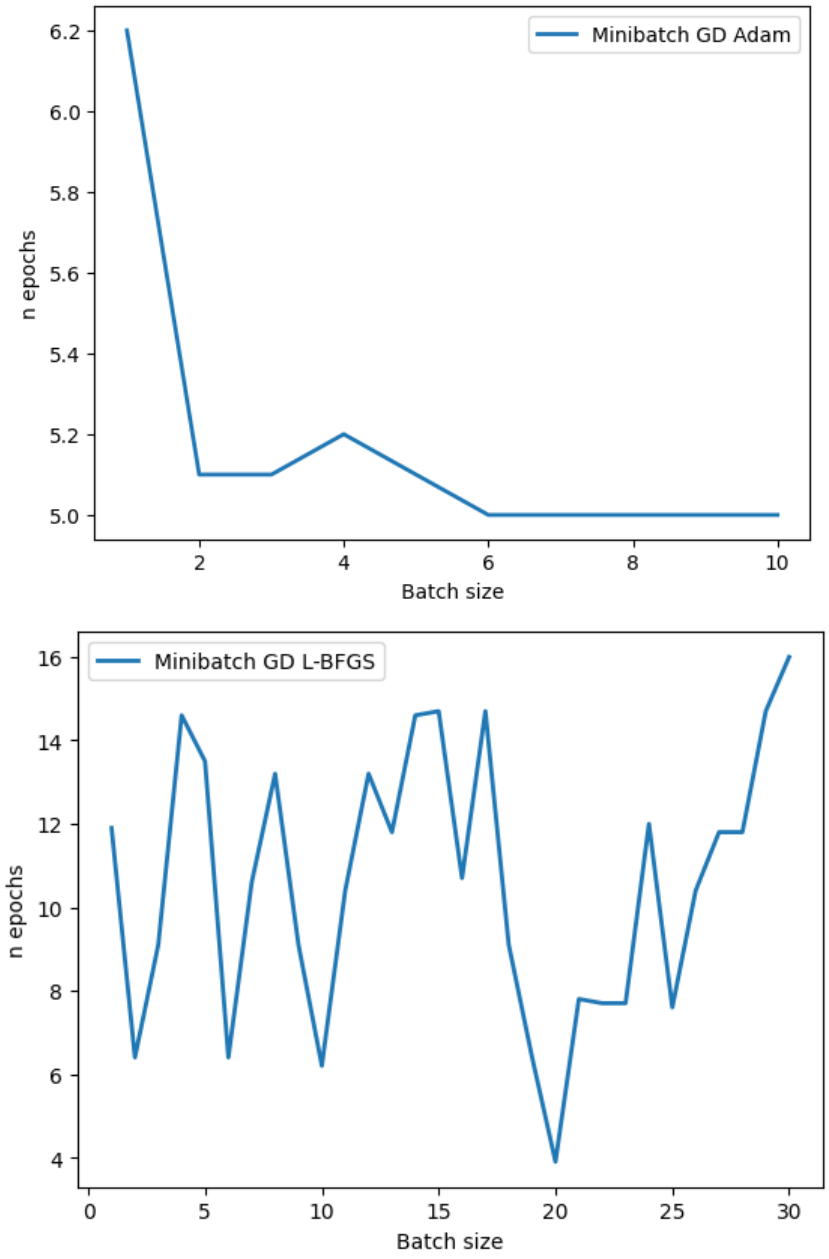

((Minibatch GD) Adam vs. L-BFGS) $\in [0, 10]$ и $\in [0, 30]$