

Национальный исследовательский университет ИТМО  
Факультет информационных технологий и программирования  
Прикладная математика и информатика

# Методы оптимизации

Отчет по лабораторной работе №3

⟨Собрано 5 июня 2023 г.⟩

**Работу выполнили:**

Бактурин Савелий Филиппович М32331

Вереня Андрей Тарасович М32331

Сотников Максим Владимирович М32331

**Преподаватель:**

Ким Станислав Евгеньевич

# Решение задачи нелинейной регрессии

Часто решая задачу создания регрессионной модели мы сталкиваемся с тем, что по жизни очень немногие рассматриваемые функции оказываются не представимы в виде обобщенной линейной зависимости или полиномиальной некоторой конечной степени  $k$ . Такая же ситуация часто случается и с некоторым набором данных, который нужно как-то обобщить. Именно в таких случаях к нам на помощь приходит более частный случай регрессионного анализа – *нелинейная регрессия*.

Идея построения нелинейной регрессии как и в случае с полиномиальной заключается в том, чтобы найти математическую функцию, которая максимально точно описывает зависимость между независимой переменной и зависимой от нее. Например, для построения нелинейной регрессии можно использовать функции типа полинома, логарифмической или экспоненциальной зависимости.

В целом весь процесс нахождения нелинейной регрессионной модели можно поделить на два этапа:

- ▷ Определить регрессионную модель  $f(w, x)$ , которая зависит от параметров  $w = (w_1, \dots, w_W)$  и свободной переменной  $x$ .
- ▷ Решить задачу по нахождению минимума суммы квадратов регрессионных остатков:

$$S = \sum_{i=1}^m r_i^2, \quad r_i = y_i - f(w, x_i)$$

Однако, решая в лоб такую задачу, мы сталкиваемся с оптимизационной задачей нахождения параметров нелинейной регрессионной модели. Тут к нам и приходят на помощь различные методы нахождения, в том числе и рассматриваемые ниже: *Gauss-Newton* и *Powell Dog Leg*.

## Gauss-Newton

Напомним, что мы решаем следующую задачу: дана нелинейная модель  $f(w, x)$ , где  $w \in \mathbb{R}^n$ , тогда сумма квадратов регрессионных остатков высчитывается как

$$S = \sum_{i=1}^{\text{sizeof } X} (f(w, x_i) - y_i)^2 \rightarrow \min$$

Итак, теперь введем некоторые новые объекты для решения задачи, пусть  $w^0 = (w_0^0, w_1^0, \dots, w_p^0)$  – начальное приближение, и

$$\mathbf{J} = \left( \frac{\partial f}{\partial w_j}(w^t, x_i) \right)_{(\text{sizeof } X) \times p} \quad - \text{Якобиан, или матрица первых производных}$$

$$\vec{f}_t = (f(w^t, x_i))_{(\text{sizeof } X) \times 1} \quad - \text{вектор значений } f$$

$$\delta_t = \text{const} \quad - \text{размера шага}$$

Тогда, формула  $t$ -й итерации рассматриваемого метода будет высчитываться как

$$w^{t+1} \leftarrow w^t - \delta_t \cdot \underbrace{(\mathbf{J}_t^T \mathbf{J}_t)^{-1} \mathbf{J}_t^T}_{\Psi} (\vec{f}_t - y),$$

где  $\Psi$  – это псевдообратная матрица, или решение некоторой задачи многомерной линейной регрессии, где мы ищем такой вектор  $\Psi$ , что

$$\left\| \mathfrak{J}_t \Psi - (\vec{f}_t - y) \right\|^2 \rightarrow \min,$$

где  $y$  – вектор правильных/настоящих ответов нашей модели. Получается, для решения задачи, мы, так называемую, *невязку* пытаемся приблизить линейной комбинацией вектора из матрицы Якобиана так, что при следующем шаге итерации получить такой  $w^{t+1}$ , который бы сократил нам расстояние невязки. Причем, заметим, что на каждом шаге, задача будет новой, так как  $\mathfrak{J}_t$  зависит от текущего приближения, чтобы решить задачу многомерной регрессии.

## Исследования

### Powell Dog Leg

## Исследования

**BFGS**

**Исследования**

**L-BFGS**

**Исследования**